

附录 A：反向 SDE 公式推导

当前已知前向 SDE 的公式为：

$$dx_t = -\theta_t(\mu - x_t) dt + \sigma_t dw_t \quad (17)$$

为方便推导，令 $-\theta_t(\mu - x) = f(x, t)$ ， $\sigma_t = g(t)$ ，

得到下述公式：

$$dx = f(x, t)dt + g(t)dw \quad (18)$$

根据该前向公式可以得到条件概率分布：

$$p(x_{t+\Delta t}|x_t) \propto \mathcal{N}(x_{t+\Delta t}; x_t + f_t(x_t)\Delta t, g_t^2\Delta t I) \propto \exp\left(-\frac{\|x_{t+\Delta t} - x_t - f_t(x_t)\Delta t\|_2^2}{2g_t^2\Delta t}\right) \quad (19)$$

根据贝叶斯定理进行如下变换：

$$\begin{aligned} p(x_t|x_{t+\Delta t}) &= \frac{p(x_{t+\Delta t}|x_t)p(x_t)}{p(x_{t+\Delta t})} = p(x_{t+\Delta t}|x_t) \exp(\log p(x_t) - \log p(x_{t+\Delta t})) \\ &\propto \exp\left(-\frac{\|x_{t+\Delta t} - x_t - f_t(x_t)\Delta t\|_2^2}{2g_t^2\Delta t} + \log p(x_t) - \log p(x_{t+\Delta t})\right) \end{aligned} \quad (20)$$

下面对 $\log p(x_{t+\Delta t})$ 做泰勒展开：

$$\log p(x_{t+\Delta t}) \approx \log p(x_t) + (x_{t+\Delta t} - x_t) \cdot \nabla_{x_t} \log p(x_t) + \Delta t \frac{\partial}{\partial t} \log p(x_t) \quad (21)$$

将该泰勒展开带入上式得到：

$$p(x_t|x_{t+\Delta t}) \propto \exp\left(-\frac{\|x_{t+\Delta t} - x_t - [f_t(x_t) - g_t^2 \nabla_{x_t} \log p(x_t)]\Delta t\|_2^2}{2g_t^2\Delta t} + O(\Delta t)\right) \quad (22)$$

当 $\Delta t \rightarrow 0$ 时， $O(\Delta t) \rightarrow 0$ 不起作用，得到：

$$p(x_t|x_{t+\Delta t}) \approx \exp\left(-\frac{\|x_t - x_{t+\Delta t} + [f_{t+\Delta t}(x_{t+\Delta t}) - g_{t+\Delta t}^2 \nabla_{x_{t+\Delta t}} \log p(x_{t+\Delta t})]\Delta t\|_2^2}{2g_{t+\Delta t}^2\Delta t}\right) \quad (23)$$

即 $p(x_t|x_{t+\Delta t})$ 近似一个均值为 $x_{t+\Delta t} - [f_{t+\Delta t}(x_{t+\Delta t}) - g_{t+\Delta t}^2 \nabla_{x_{t+\Delta t}} \log p(x_{t+\Delta t})]\Delta t$ ，协方差为 $g_{t+\Delta t}^2 \Delta t I$

的正态分布，取 $\Delta t \rightarrow 0$ 得到：

$$dx = [f_t(x) - g_t^2 \nabla_x \log p_t(x)]dt + g_t d\hat{w} \quad (24)$$

即：

$$dx = [f(x, t) - g(t)^2 \nabla_x \log p_t(x)]dt + g_t d\hat{w} \quad (25)$$

代入 $f(x, t) = -\theta_t(\mu - x)$ ， $g(t) = \sigma_t$ 得到：

$$dx = [\theta_t(\mu - x) - \sigma_t^2 \nabla_x \log p_t(x)]dt + \sigma_t d\hat{w} \quad (26)$$

附录 B：SDE 最优状态求解推导

本文采用最大似然法求解最优状态 x_{i-1}^* ，然后使用最优状态进行损失约束：

$$x_{i-1}^* = \arg \min_{x_{i-1}} \{ -\log p(x_{i-1}|x_i, x_0) \} \quad (27)$$

使用贝叶斯公式得到:

$$\begin{aligned} -\log p(x_{i-1}|x_i, x_0) &= -\log \frac{p(x_i|x_{i-1}, x_0)p(x_{i-1}|x_0)}{p(x_i|x_0)} \\ &\propto -\log p(x_i|x_{i-1}, x_0) - \log p(x_{i-1}|x_0) \end{aligned} \quad (28)$$

通过求解其梯度并设为 0 得到:

$$\begin{aligned} \nabla_{x_{i-1}^*} \{ -\log p(x_{i-1}^*|x_i, x_0) \} &\propto -\nabla_{x_{i-1}^*} \log p(x_i|x_{i-1}^*, x_0) - \nabla_{x_{i-1}^*} \log p(x_{i-1}^*|x_0) \\ &= -\frac{e^{-\theta_i'}(x_i - \mu - (x_{i-1}^* - \mu)e^{-\theta_i'})}{1 - e^{-2\theta_i'}} + \frac{x_{i-1}^* - \mu - (x_0 - \mu)e^{-\bar{\theta}_{i-1}}}{1 - e^{-2\bar{\theta}_{i-1}}} \\ &= \frac{(x_{i-1}^* - \mu)e^{-2\theta_i'}}{1 - e^{-2\theta_i'}} + \frac{(x_{i-1}^* - \mu)}{1 - e^{-2\bar{\theta}_{i-1}}} - \frac{(x_i - \mu)e^{-\theta_i'}}{1 - e^{-2\theta_i'}} - \frac{(x_0 - \mu)e^{-\bar{\theta}_{i-1}}}{1 - e^{-2\bar{\theta}_{i-1}}} \\ &= \frac{(x_{i-1}^* - \mu)(1 - e^{-2\bar{\theta}_{i-1}})}{(1 - e^{-2\theta_i'})(1 - e^{-2\bar{\theta}_{i-1}})} - \frac{(x_i - \mu)e^{-\theta_i'}}{1 - e^{-2\bar{\theta}_{i-1}}} = 0 \end{aligned} \quad (29)$$

其中 $\theta_i' = \int_{i-1}^i \theta_t dt$, 上式化简可得:

$$x_{i-1}^* = \frac{1 - e^{-2\bar{\theta}_{i-1}}}{1 - e^{-2\bar{\theta}_i}} e^{-\theta_i'} (x_i - \mu) + \frac{1 - e^{-2\theta_i'}}{1 - e^{-2\bar{\theta}_i}} e^{-\bar{\theta}_{i-1}} (x_0 - \mu) + \mu \quad (30)$$

到此即得到最优的 $i-1$ 状态。

附录 C: 数据集标注规范

本文数据集首先使用 labelme 对异常扣件进行标注, 框出异常扣件, 记录保存扣件类型及位置信息, 生成 json 文件, 依据该 json 文件即可提取出异常前景。标注示意如图所示:



图 1 数据集标注示意图

Fig.1 Dataset Annotation Illustration

异常扣件在本文中被分为五种类型，分别是移位、断裂、变形、反装、缺失，如图所示：




图 2 异常扣件类型

Fig.2 Abnormal Fastener Types

附录 D：数据集构建

为了构建数据集，本文首先对轨道图像进行了标注，提取出其中的异常扣件区域，形成异常扣件子集。随后，对于每张轨道图像，本文从该子集中随机选取一张同类型的异常扣件图像，通过直方图匹配技术将原图中对应的异常区域的像素灰度分布特征调整至与选取的异常扣件图像一致，从而使原图异常区域呈现出与所选图像相同的视觉风格，以此生成一张合成图像。最终，本文将合成图像与原始轨道图像及其对应的掩码图像配对，构成一个图像对。具体过程如图 2 所示。




图 3 数据集构建

Fig.3 Dataset Construction